

شبیه سازی متلب روش شبکه عصبی کانولوشن

در تشخیص بیماریهای پوستی


فهرست مطالب

1	شبیه سازی متلب روش شبکه عصبی کانولوشن
1	در تشخیص بیماریهای پوستی
2	هدف و خلاصه
2	آنالیز داده و پیش پردازش
3	شبکه عصبی کانولوشن چیست و چگونه از آن در دسته بندی تصاویر استفاده می شود
3	شیوه عملکرد شبکه عصبی کانولوشن چیست؟
4	ارتباط شبکه عصبی پیچشی با زیست شناسی
4	ساختار شبکه عصبی پیچشی چیست؟
4	پردازش
4	لایه اول در شبکه عصبی کانولوشن مفاهیم ریاضیاتی
4	لایه اول در شبکه عصبی کانولوشن
5	لایه های عمیق تر شبکه عصبی کانولوشن
5	لایه آخر در شبکه عصبی پیچشی
5	نحوه عملکرد شبکه عصبی کانولوشن چیست؟
5	تست شبکه عصبی CNN
6	تعریف
7	حساسیت
7	Specificity
9	روند شبیه سازی
9	
10	انتخاب داده
12	نتیجه

هدف و خلاصه

سرطان پوست در طول سالهای گذشته رشد چشمگیری داشته است و اهمیت درمان اولیه آن روز به روز در حال افزایش است. هدف از این تحقیق، استفاده از شبکه های عصبی عمیق کانولوشنال برای ایجاد يك سیستم خودکار تشخیص هفت بیماری شایع پوستی از قبیل ملانوما، کارسینوم سلول بازال، ملانسیستیک نووس، درماتوفیبروما، کراتوز آکتینیک، کراتوز خوش خیم، ضایعه های عروقی بوده است که در آن داده ها به طور مستقیم به عنوان بخشی از فرآیند یادگیری عمیق کنترل میشود.

در این پژوهش مطالعات بر روی تصاویر مربوط به سرطان پوست انجام شده است. برای تشخیص خوشخیم یا بدخیم بودن سرطان پوست از طبقه بندی کننده کانولوشنال شبکه عصبی عمیق به کمک نرم افزار متلب و تبدیل موجک گسسته دو بعدی که الگوریتم مبتنی بر کانولوشن فریمورک و بهره گیری از کتابخانه استفاده شده است. مجموعه داده مورد استفاده در این پژوهش از 14 تصویر ملانوما و 100 تصویر مربوط به خال گوشتی خوش خیم تشکیل شده است. در مدل پی‌شهادی این پژوهش 80 درصد از تصاویر پایگاه داده برای آموزش و 20 درصد تصاویر پایگاه داده برای آزمون انتخاب میشود.



آنالیز داده و پیش پردازش

جمع آوری تصاویر داده ها متشکل از بیماریهای پوستی عبارتند از:

Skin Disease Abbreviation	Description	Farsi
BCC	Basal cell carcinoma	کارسینوم سلول بازال
M	Melanoma	ملانوما
N	Melanocytic Nevus	ملانسیستیک نووس
D	Dermatofibroma	درماتوفیبروما
AK	Actinic Keratosis	کراتوز آکتینیک
PBK	Planus-like Benign Keratosis	کراتوز خوش خیم
VL	Vascular Lesion	ضایعه های عروقی

BCC: نوعی سرطان پوست که معمولاً در صورت بروز می کند و اغلب به بافت اطراف حمله می کند اما به ندرت متاستاز می کند.

*متاستاز: گسترش سرطان به سایر نقاط بدن.

Melanoma: تومور سیاه رنگ قشر عمیق پوست

Melanocytic Nevus : سرطانی شدن یک علامت تولد یا یک خال روی پوست ، به خصوص یک علامت تولد به شکل یک وصله قرمز برجسته.

Dermatofibroma توده پوستی کوچکی است که معمولاً بصورت منفرد و به اندازه نیم تا یک سانت قطر دارد و در پوست ایرانیان معمولاً برنگ قهوه ای دیده می شود

Actinic Keratosis: کراتوز آکتینیک یک بیماری پوستی ناشی از قرار گرفتن طولانی مدت در معرض آفتاب است. پوست آسیب دیده، نقاط کوچک، قرمز، خشن، پوسته پوسته شده و مسطح را نشان می دهد.

Planus-like Benign Keratosis : کراتوز خوش خیم شبه پلان: کراتوز سبورئیک، که به آن زگیل سبورئیک یا زگیل پیری نیز می گویند، تومور پوستی خوش خیمی است که از کراتینوسیت ها سرچشمه می گیرد. مانند لکه های پیری، کراتوزهای سبورئیک نیز با بالا رفتن سن بیشتر دیده می شوند.

Vascular Lesion: ضایعه های عروقی پوستی، ضایعه هایی به شکل خال، لك، زخم یا توده های خوش خیم و بدخیم هستند که جزو اصلی تشکیل دهنده شان رگ های سرخرگی. سیاهرگی و لنفاوی است.

شبکه عصبی کانولوشن

شبکه عصبی پیچشی یا شبکه عصبی کانولوشن، از مهم ترین نوآوری ها در حوزه ی بینایی کامپیوتر به حساب می آیند؛ و بیش ترین استفاده ی شبکه عصبی در پردازش تصویر است.

شبکه عصبی کانولوشن چیست و چگونه از آن در دسته بندی تصاویر استفاده می شود

دسته بندی تصاویر (image classification) در حقیقت فرایندی است که در آن تعدادی تصویر از ورودی می گیریم و در خروجی، کلاس آن ها مثلاً (بازال، ملانوما، نووس، درماتوفیبروما، کراتوز آکتینیک، کراتوز خوش خیم، ضایعه های عروقی و ...) یا درصد احتمال تعلق به هر کلاس را مشخص می کنیم. وقتی یک CNN تصویری را به عنوان ورودی دریافت می کند، آن را به صورت آرایه ای از اعداد می بیند. تعداد آرایه ها به ساین تصویر (بر اساس پیکسل) بستگی دارد. برای مثال اگر یک تصویر رنگی با فرمت JPG و اندازه ۸۰ * ۸۰ پیکسل را به CNN دهیم، آرایه جانشین آن دارای ۸۰ * ۸۰ * ۳ خانه خواهد بود (عدد ۳ به RGB برمی گردد). (هر کدام از خانه های نیز عددی بین ۰ تا ۲۵۵ را می گیرند. این عدد شدت پیکسلی را نشان می دهد. این اعداد در دسته بندی تصاویر با استفاده از شبکه عصبی کانولوشن، نماینگر تصویر به زبان آرایه ها است. ایده اصلی آن است که به CNN آرایه ای از اعداد را می دهیم و CNN نیز در خروجی نام بیماریها را مشخص می کند.

شیوه عملکرد شبکه عصبی کانولوشن چیست؟

برای درک و تشخیص تصویرهای پیچیده ای مثل تصویر یک بیماری پوستی، ابتدا ویژگی های (feature) ساده تر آن تصویر مانند لبه ها و خم ها را تشخیص می دهد. در یک شبکه عصبی، لایه های متعددی وجود دارند؛ در هر یک از این لایه ها، ویژگی های خاصی تشخیص داده می شوند و در نهایت، در لایه ی آخر، تصویر به طور کامل شناسایی می شود. روندی که توضیح دادیم، فرایند کلی نحوه کار یک شبکه عصبی کانولوشن بود؛ حال به جزئیات بیش تری می پردازیم.

ارتباط شبکه عصبی پیچشی با زیست شناسی

ساختار شبکه عصبی پیچشی (CNN) در حقیقت از قشر بینایی مغز الهام گرفته شده است. با دیدن لبه‌ها با اشکال مختلف، سلول‌های خاصی در قشر بینایی مغز تحریک می‌شوند. برای مثال با دیدن خطوط افقی، سلول‌های خاصی تحریک می‌شوند و با دیدن خطوط عمود بر هم سلول‌های متفاوتی حساسیت نشان می‌دهند. هابل و ویزل دریافتند که این سلول‌ها به شکل ستونی و خیلی منظم در کنار همدیگر قرار گرفته‌اند و حاصل همکاری آن‌ها با هم این است که ما می‌توانیم ادراک تصویری خوبی از محیط پیرامون داشته باشیم. اساس کار شبکه عصبی کانولوشن نیز مانند قشر بینایی مغز ماست! در حقیقت در یک CNN، لایه‌های مختلفی وجود دارند که هر یک لایه مخصوص شناسایی موارد خاصی است. در نهایت نیز خروجی مدل ادراک تصویری کامل است.

ساختار شبکه عصبی پیچشی چیست؟

همان‌طور که اشاره شد، در یک شبکه عصبی پیچشی، کامپیوتر یک تصویر را به عنوان ورودی می‌گیرد؛ سپس این تصویر وارد یک شبکه‌ی پیچیده با چندین لایه‌ی پیچشی و غیر خطی می‌شود. در هر یک از این لایه‌ها، عملیات‌هایی انجام می‌شود و در انتها بر روی خروجی، یک کلاس یا درصد وقوع چند کلاس مختلف نشان داده می‌شود.

پردازش

لایه اول در شبکه عصبی کانولوشن | مفاهیم ریاضیاتی

لایه اول در یک شبکه عصبی پیچشی، همیشه یک لایه‌ی کانولوشن است. همان‌طور که قبلاً اشاره کردیم، ورودی این لایه یک آرایه از اعداد است. لایه اول در شبکه عصبی مانند یک چراغ قوه کار می‌کند. در یک اتاق تاریک، چراغ قوه‌ای را تصور کنید که بر گوشه‌ی بالا و سمت چپ تصویر می‌اندازیم و محدوده‌ای از تصویر روشن می‌شود و آن قسمت را می‌بینیم. سپس چراغ قوه را بر روی قسمت‌های دیگر تصویر می‌گیریم تا کم‌کم کل تصویر را ببینیم. در شبکه عصبی کانولوشن، به این (یا نورون یا کرنل) می‌گوییم. آن قسمتی از تصویر که چراغ قوه به آن نور می‌تاباند، محدود پذیرش (filter) چراغ قوه، فیلتر یا (weight) نام دارد. فیلترها نیز خود آرایه‌هایی از اعداد هستند. به اعداد موجود در فیلتر، وزن (receptive field) گفته می‌شود. لازم به ذکر است که عمق این فیلتر باید با عمق تصویر برابر باشد. مثلاً اگر تصویر (parameter) پارامتر یک آرایه عددی $3 \times 5 \times 5$ (عمق ۳) است، فیلتر نیز باید چنین باشد. فیلتر در هر نگاه، یک قسمت از تصویر را می‌بیند. سپس بر روی تصویر حرکت می‌کند تا قسمت‌های دیگر را هم اسکن کند. به این حرکت فیلتر بر روی تصویر، پیچیدن می‌گویند. همین‌طور که فیلتر از تصویر عبور می‌کند، اعداد موجود در فیلتر با آرایه عددی پیکسل‌های (convolve) تصویر ضرب می‌شود. در نهایت نیز تمام حاصل ضرب‌ها با یکدیگر جمع می‌شوند و به یک عدد می‌رسیم. فرض کنید می‌خواهیم یک تصویر با ابعاد $32 \times 32 \times 3$ را با استفاده از یک فیلتر $5 \times 5 \times 3$ ببینیم. این فیلتر با عملیاتی که توضیح دادیم در نهایت یک آرایه عددی با ابعاد $28 \times 28 \times 1$ تولید می‌کند (علت 28×28 بودن آن است که به 784 حالت می‌توان یک تصویر 32×32 را با استفاده از فیلتر 5×5 دید). به ماتریس $28 \times 28 \times 1$ که در نهایت به دست می‌آید نقشه فعال‌سازی می‌گوییم. اگر به جای یک فیلتر، از دو فیلتر استفاده کنیم، در (feature map) یا نقشه ویژگی (activation map) نهایت به یک ماتریس با ابعاد $28 \times 28 \times 2$ می‌رسیم. این کار می‌تواند دقت ما را در ابعاد بالاتر افزایش دهد.

لایه اول در شبکه عصبی کانولوشن

هر یک از فیلترهایی را که در قسمت قبلی به آن‌ها اشاره کردیم، می‌توان به عنوان یک شناساگر ویژگی (feature identifier) در نظر گرفت. منظور از ویژگی (feature) در این جا، چیزهایی مانند خط صاف، یک رنگ ساده یا یک انحناست. فرض کنیم فیلتر اول، یک فیلتر با ابعاد $7 \times 7 \times 3$ و یک شناساگر انحناست. این فیلتر در حقیقت یک ماتریس عددی مانند تصویر زیر است که درایه‌های این ماتریس در محل‌هایی که انحنا وجود دارد، مقادیر عددی بالاتری دارند. حال این فیلتر را بر روی قسمتی از تصویر مد نظرمان قرار می‌دهیم. پس از آن مانند تصویر زیر، درایه به درایه اعداد موجود در خانه‌ها را با هم ضرب و حاصل ضرب‌ها را با یکدیگر جمع می‌کنیم.

همانطور که مشاهده می کنید، حاصل به دست آمده، یک عدد بزرگ است. بزرگ بودن این عدد نشانگر آن است که در این ناحیه یک انحنا مانند انحنای فیلتر وجود دارد.

سپس حاصل ضرب عدد کوچکی می شود؛ علت آن است که فیلتر با تصویر ورودی تطابق ندارد. همان طور که اشاره کردیم، ما در پی آن هستیم که یک نقشه فعال سازی به دست بیاوریم؛ یعنی یک آرایه از اعداد با ابعاد $1 * 26 * 26$ (فرض کنیم فقط از یک فیلتر شناساگر منحنی استفاده کنیم). قسمت بالا و سمت چپ این نقشه فعال سازی، مقدار ۶۶۰ را خواهد داشت. این عدد بزرگ نشان دهنده ی آن است که در ناحیه ی خاصی از تصویر، با احتمال زیاد یک منحنی وجود دارد. توجه کنید که ما در این جا تنها از یک فیلتر استفاده کردیم. برای آن که اطلاعات بیش تری از تصویر استخراج کنیم، نیاز داریم تا از فیلترهای بیش تری استفاده کنیم؛ استفاده از فیلترهای بیش تر یعنی ابعاد بالاتر

لایه های عمیق تر شبکه عصبی کانولوشن

در یک شبکه عصبی، علاوه بر لایه ی توضیح داده شده، لایه های دیگری نیز وجود دارند. این لایه ها وظایف و عملکردهای گوناگونی دارند. به طور کلی، لایه های داخلی، مسئول نگهداری و حفظ ابعاد و امور غیرخطی هستند. آخرین لایه در شبکه عصبی کانولوشن نیز از اهمیت خاصی برخوردار است.

لایه آخر در شبکه عصبی پیچشی

در لایه آخر یک شبکه عصبی کانولوشن، خروجی سایر لایه ها، به عنوان ورودی دریافت می شود. خروجی لایه آخر هم یک تعداد کلاس های موجود است. به عنوان مثال اگر شبکه ی شما، یک شبکه برای شناسایی اعداد N باشد. بعدی است N بردار بعدی، هر مولفه، احتمال وقوع یک کلاس را نشان می دهد. N باشد، تعداد کلاس ها ده تا است؛ چون ده رقم داریم. در بردار کاری که لایه ی آخر یک شبکه عصبی کانولوشن می کند آن است که به ویژگی های لایه های سطح بالا نگاه می کند و میزان مطابقت این ویژگی ها را با هر کلاس مقایسه می کند؛ هر چه این مطابقت بیش تر باشد، احتمال وقوع آن کلاس، بالاتر معرفی می شود.

نحوه عملکرد شبکه عصبی کانولوشن چیست؟

CNN تست شبکه عصبی

پس از آن که مدل ما نهایی و آماده شد، وقت تست کردن فرا می رسد. برای تست مدل از تعدادی تصویر که می دانیم محتویات آن چیست، استفاده می شود. تصویر را به ورودی مدل می دهیم تا خروجی را به ما نشان دهد؛ سپس خروجی را بررسی می کنیم تا ببینیم درست عمل شده است یا نه.

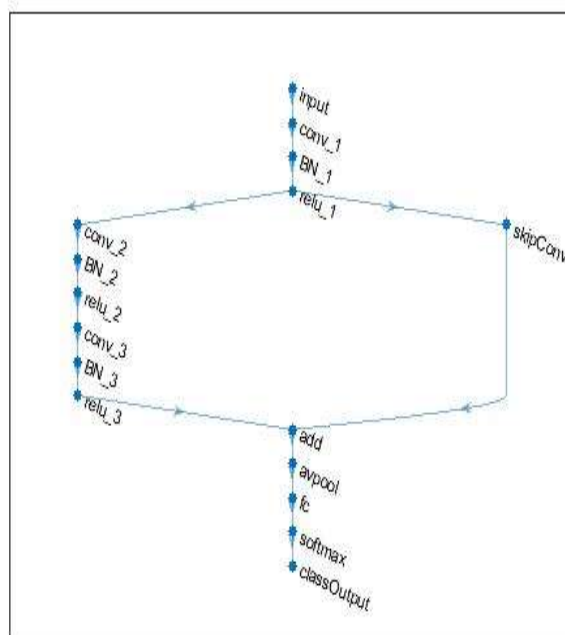
جستجو در تصویر برای یافتن تنها یک الگو منجر به نتایج خوبی نمی شود و باعث می شود شبکه از لحاظ کارایی محدود باشد. برای حل این مشکل، نیاز است که لایه کانولوشنی چندین فیلتر داشته باشد. **هریک از فیلترها به تنهایی یک الگوی خاص داشته باشند و خروجی لایه کانولوشنی مجموعه ای از الگوهای مختلف باشد.** تصویر با فیلترهای مختلفی کانوالو شده و هر فیلتر هم یک خروجی جداگانه برای خود تولید کرده است. همه تصاویر مربوط به یک چهره با ماسک هست؛ اما دقت کنید که در هر تصویری یک مجموعه ویژگی خاص مورد توجه بوده است. مثلاً در تصویری، لبه های افقی، در دیگری لبه های عمودی و غیره.

اندازه stride را می توان گام هم تعریف کرد. منظور از گام این است که فیلتر بعد از محاسبه در یک پنجره از ورودی، چند درایه یا خانه باید جلو برود تا دوباره محاسبات را انجام دهد. اگر اندازه گام را 1 در نظر بگیریم، یعنی فیلتر باید درایه به درایه در ورودی به سمت راست و پایین برود و اسکن را انجام دهد. یعنی، همان صحبت هایی که در بخش قبل (کانولوشن) داشتیم. اما اگر مثلاً stride عدد 2 در نظر گرفته شود.

لایه پولینگ یکی دیگر از لایه های مهم در شبکه عصبی کانولوشن است. هدف لایه پولینگ کاهش اندازه مکانی فیچر کمپ بدست آمده با استفاده از لایه کانولوشنی است. **لایه پولینگ پارامتر قابل آموزش ندارد.** صرفاً یک نمونه برداری ساده و موثر انجام می دهد. پولینگ عملکردی شبیه کانولوشن دارد و یک پنجره روی تصویر حرکت می کند. رایج ترین نمونه

پولینگ **max pooling** و **average pooling** است. ماکس پولینگ شامل یک پنجره از پیش تعریف شده است (مثلا 3×3) که روی تصویر حرکت می‌کند (تصویر را اسکن می‌کند) و در هر پنجره مقدار ماکزیمم را انتخاب می‌کند و بقیه را دور می‌ریزد. مشابه با لایه کانولوشنی، اندازه فیلتر، پدینگ و استراید در اینجا هم صدق می‌کند. در پولینگ، معمولاً استراید 2 و اندازه فیلتر 3 در نظر گرفته می‌شود. برای اینکه سائز ویژگی به $2/1$ کاهش پیدا کند.

معمولاً آخرین لایه های یک شبکه عصبی کانولوشن برای طبقه بندی را لایه های فولی کانکتد تشکیل می‌دهند. این لایه ها همان لایه هایی هستند که در شبکه عصبی MLP دیده‌اید. برای آشنایی بیشتر این مقاله را بخوانید. یکی از کاربردهای اصلی لایه فولی کانکتد در شبکه کانولوشن، استفاده به عنوان طبقه بند یا **کلاسیفایر (Classifier)** است. یعنی مجموعه ویژگی‌های استخراج شده با استفاده از لایه های کانولوشنی در نهایت تبدیل به یک بردار می‌شوند. در نهایت این بردار ویژگی به یک کلاسیفایر فولی کانکتد داده می‌شود تا کلاس درست را شناسایی کند. من این جا CNN با فولی کانکتد کامل کردم. شکل زیر بلوک دیاگرام کامل یک شبکه عصبی کانولوشن ساده برای طبقه بندی است.



متدولوژی و پیاده سازی

تعریف حساسیت

حساسیت و تشخیص پذیری دو شاخص مهم برای ارزیابی آماری عملکرد نتایج آزمون‌های طبقه‌بندی باینری (دودویی یا دوحالته) هستند، که در آمار به عنوان توابع طبقه‌بندی شناخته می‌شوند. نتایج را بعد از تحلیل می‌توان به دو گروه داده مثبت و منفی تقسیم کرد. روش های آزمون و ارزیابی، نتایج یک آزمایش را به این دو دسته تقسیم می‌کند. سپس کیفیت الگوریتم با استفاده از شاخص‌های حساسیت و تشخیص پذیری قابل اندازه‌گیری و توصیف می‌شوند.

در نهایت بعد از هر تحلیلی نتایج به دست آمده را باید در چهار گروهی که در بالا توصیف شد، دسته بندی کرد تا بتوان کیفیت تحلیل را مورد ارزیابی قرار داد. همچنین کارایی الگوریتم را برای موارد استفاده مختلف تفسیر و توصیف نمود. در ارزیابی نتایج معمولا معیارهای زیر متصور است و بیشترین استفاده را نسبت به معیارهای ارزیابی دیگر دارد

تشکیل ماتریس اختلاط (confusion matrix)

دقت (Accuracy)

صحت (Precision)

Recall زمانی که ارزش false negatives بالا باشد، معیار Recall، معیار مناسبی خواهد بود.

F1 Score

به طور کلی، دقت به این معناست که مدل تا چه اندازه خروجی را درست پیش بینی می کند. با نگاه کردن به دقت، بلافاصله می توان دریافت که آیا مدل درست آموزش دیده است یا خیر و کارایی آن به طور کلی چگونه است. اما این معیار اطلاعات جزئی در مورد کارایی مدل ارائه نمی دهد.

$$\text{Accuracy} = (TP+TN) / (TP+FN+FP+TN)$$

وقتی که مدل نتیجه را مثبت (positive) پیش بینی می کند، این نتیجه تا چه اندازه درست است؟ زمانی که ارزش false positives بالا باشد، معیار صحت، معیار مناسبی خواهد بود. فرض کنید، مدلی برای تشخیص سرطان داشته باشیم و این مدل Precision پایینی داشته باشد. نتیجه این امر این است که این مدل، بیماری بسیاری از افراد را به اشتباه سرطان تشخیص می دهد. نتیجه این امر استرس زیاد، آزمایش های فراوان و هزینه های گزافی را برای بیمار به دنبال خواهد داشت.

$$\text{Precision} = TP / (TP+FP)$$

حساسیت

در واقع، «حساسیت» معیاری است که مشخص می کند دسته بندی، به چه اندازه در تشخیص تمام افراد مبتلا به بیماری موفق بوده است. همانگونه که از رابطه فوق مشخص است، تعداد افراد سالمی که توسط دسته بندی به اشتباه به عنوان فرد بیمار تشخیص داده شده اند، هیچ تاثیری در محاسبه این پارامتر ندارد و در واقع زمانی که پژوهشگر از این پارامتر به عنوان پارامتر ارزیابی برای دسته بندی خود استفاده می کند، هدفش دستیابی به نهایت دقت در تشخیص نمونه های کلاس مثبت است.

Specificity

در نقطه مقابل این پارامتر، ممکن است در مواقعی دقت تشخیص کلاس منفی حائز اهمیت باشد. از متداول ترین پارامترها که معمولا در کنار حساسیت بررسی می شود، پارامتر خاصیت (Specificity)، است که به آن «نرخ پاسخ های منفی

درست (True Negative Rate) «نیز می‌گویند. خاصیت به معنی نسبتی از موارد منفی است که آزمایش آن‌ها را به درستی به عنوان نمونه منفی تشخیص داده است. این پارامتر به صورت زیر محاسبه می‌شود.

زمانی که ارزش false negatives بالا باشد، معیار Recall، معیار مناسبی خواهد بود. فرض کنیم مدلی برای تشخیص بیماری کشنده ابولا داشته باشیم. اگر این مدل Recall پایینی داشته باشد چه اتفاقی خواهد افتاد؟ این مدل افراد زیادی که آلوده به این بیماری کشنده هستند را سالم در نظر می‌گیرد و این فاجعه است. نسبت مقداری موارد صحیح طبقه‌بندی شده توسط الگوریتم از یک کلاس به تعداد موارد حاضر در کلاس مذکور که به صورت زیر محاسبه می‌شود:


$$\text{Recall} = \text{Sensitivity} = (\text{TPR}) = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

معیار F1، یک معیار مناسب برای ارزیابی دقت یک آزمایش است. این معیار Precision و Recall را با هم در نظر می‌گیرد. معیار F1 در بهترین حالت، یک و در بدترین حالت صفر است.

$$\text{F-measure} = 2 * (\text{Recall} * \text{Precision}) / (\text{Recall} + \text{Precision})$$

در نقطه مقابل این پارامتر، ممکن است در مواقعی دقت تشخیص کلاس منفی حائز اهمیت باشد. از متداول‌ترین پارامترها که معمولاً در کنار حساسیت بررسی می‌شود، پارامتر خاصیت (Specificity)، است که به آن «نرخ پاسخ‌های منفی درست (True Negative Rate)» نیز می‌گویند. خاصیت به معنی نسبتی از موارد منفی است که آزمایش آن‌ها را به درستی به عنوان نمونه منفی تشخیص داده است. این پارامتر به صورت زیر محاسبه می‌شود.

$$\text{Specificity (TNR)} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$



انتخاب داده

← → ↻ isic-archive.com/#/onlyHeaderTop/gallery?filter=%5B%22meta.clinical.diagnosis%7Cactinic%20keratosis%22%5D

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL DataSet Concrete opencv Reading list

Search by filters Search by name

Actinic Keratosis

APPLIED FILTERS Clear applied filters

Lesion Diagnosis: actinic keratosis

DIAGNOSTIC ATTRIBUTES

BENIGN OR MALIGNANT

LESION DIAGNOSIS

Select All

Select None

☒ actinic keratosis (869)

☐ angiofibroma or fibrous papule (0 / 1)

☐ angioma (0 / 15)

☐ atypical melanocytic proliferation (0 / 14)

☐ basal cell carcinoma (0 / 3396)

☐ cafe-au-lait macule (0 / 1)

Shown images: 1-80. Filtered images: 869 Total amount of images: 69445

Select All on the Page for Download

Unselect 9 images

1 of 11

ISIC_0073122

ISIC_0073155

ISIC_0073170

ISIC_0016057

ISIC_0016049

ISIC_0071998

ISIC_0071645

ISIC_0071444

ISIC_0071490

← → ↻ isic-archive.com/#/onlyHeaderTop/gallery?filter=%5B%22meta.clinical.diagnosis%7Cbasal%20cell%20carcinoma%22%5D

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL DataSet Concrete opencv Reading list

Search by filters Search by name

Search images

APPLIED FILTERS Clear applied filters

Lesion Diagnosis: basal cell carcinoma

DIAGNOSTIC ATTRIBUTES

BENIGN OR MALIGNANT

LESION DIAGNOSIS

Select All

Select None

☐ actinic keratosis (0 / 869)

☐ angiofibroma or fibrous papule (0 / 1)

☐ angioma (0 / 15)

☐ atypical melanocytic proliferation (0 / 14)

☒ basal cell carcinoma (3396)

☐ cafe-au-lait macule (0 / 1)

☐ dermatofibroma (0 / 246)

Shown images: 1-80. Filtered images: 3396 Total amount of images: 69445

Select All on the Page for Download

Unselect 3 images

1 of 43

ISIC_0073122

ISIC_0073155

ISIC_0073170

← → ↻ isic-archive.com/#/onlyHeaderTop/gallery?filter=%5B%22meta.clinical.diagnosis%7Cdermatofibroma%22%5D

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL DataSet Concrete opencv Reading list

Search by filters Search by name

Dermatofibroma

APPLIED FILTERS Clear applied filters

Lesion Diagnosis: dermatofibroma

DIAGNOSTIC ATTRIBUTES

BENIGN OR MALIGNANT

LESION DIAGNOSIS

Select All

Select None

☐ cafe-au-lait macule (0 / 1)

☒ dermatofibroma (246)

☐ lentigo NOS (0 / 111)

☐ lentigo simplex (0 / 27)

☐ lichenoid keratosis (0 / 32)

☐ melanoma (0 / 5598)

☐ nevus (0 / 27878)

☐ other (0 / 10)

☐ pigmented benign keratosis (0 / 1099)

☐ scar (0 / 1)

☐ seborrheic keratosis (0 / 1464)

☐ solar lentigo (0 / 270)

Shown images: 1-80. Filtered images: 246 Total amount of images: 69445

Select All on the Page for Download

Unselect 7 images

1 of 4

ISIC_0073122

ISIC_0073155

ISIC_0073170

ISIC_0016057

ISIC_0016049

ISIC_0071998

ISIC_0071645

← → ↻ isic-archive.com/#/onlyHeaderTop/gallery?filter=%5B%7B%22meta.clinical.diagnosis%7C%22%3A%22n%22%22%7D%5D

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL DataSet Concrete openv Reading list

Search by filters Search by name

Nevus

APPLIED FILTERS Clear applied filters


Lesion Diagnosis: nevus

Nevus Type: nevus NOS

dermatofibroma (0 / 1)
dermatofibroma (0 / 246)
lentigo NOS (0 / 111)
lentigo simplex (0 / 27)
lichenoid keratosis (0 / 32)
melanoma (0 / 5598)
☒ nevus (551 / 27878)
other (0 / 10)
pigmented benign keratosis (0 / 1099)
scar (0 / 1)
seborrheic keratosis (0 / 1464)
solar lentigo (0 / 270)

Shown images: 1-80. Filtered images: 551 Total amount of images: 69445

Select All on the Page for Download
Unselect 5 images



ISIC_0073122
ISIC_0073155
ISIC_0073170
ISIC_0016057
ISIC_0016049

← → ↻ researchgate.net/publication/333624070_Diffuse_lichen_planus-like_keratosis_and_clinical_pseudo-progression_associated

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL

Diffuse lichen planus-like keratosis and clinical pseudo-progression associated with avelumab treatment for Merkel cell carcinoma, a case report

Article Jun 2019

Download



← → ↻ isic-archive.com/#/onlyHeaderTop/gallery?filter=%5B%7B%22meta.clinical.diagnosis%7C%22%3A%22v%22%22%7D%5D

Apps Code cuda cuda code matlab EEG documentx Articles RBM nlp knee HDL DataSet Concrete

Search by filters Search by name

Vascular Lesion

APPLIED FILTERS Clear applied filters

Lesion Diagnosis: vascular lesion

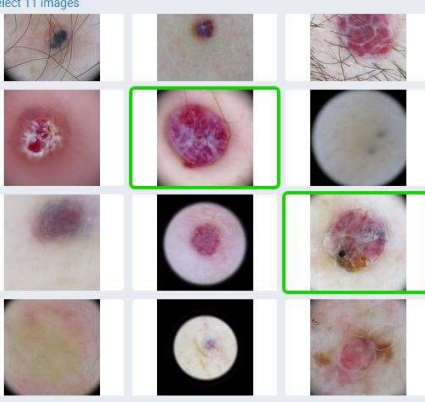
squamous cell carcinoma (0 / 656)
☒ vascular lesion (253)
unknown (0 / 27504)

CLINICAL ATTRIBUTES

APPROXIMATE AGE
GENERAL ANATOMIC SITE
CLINICAL SIZE - LONGEST DIAMETER (MM)
TYPE OF DIAGNOSIS
FAMILY HISTORY OF MELANOMA

Shown images: 1-80. Filtered images: 253 Total amount of images: 6944


Select All on the Page for Download
Unselect 11 images



نتیجه گیری

در این تحقیق، یک روش مدل کانولوشن عصبی و تست برای تشخیص بیماری پوستی در نظر گرفته شده است. مدل CNN پیش بینی نسبتاً دقیقی از تصاویر نمونه مجموعه داده بایگانی ISIC ارائه کرده است و با توجه به معیارهایی چون ماتریکس وابستگی، دقت، صحت، خاصیت و حساسیت اثبات شد که CNN بطور موفق عمل نموده است. گرچه تجزیه و تحلیل داده های بیشتر برای بهبود دقت آن لازم است، CNN برای طبقه بندی بیماری ها و به ویژه برای تشخیص زودهنگام سرطان های پوست مفید است.

علاوه بر نتیجه گیریهای مقاله مبنای می توان نتیجه گیری بسیار مهمی بر پایه ماتریکس وابستگی داشت که شباهت تصاویر برخی بیماریها به هم نزدیک است و نیاز به بهبود مدل برای افتراق هر چه بیشتر را دارد. مانند بازال با درماتوفیروما و آکتینیک، همچنین ملانوما و کراتوز خوش خیم.



AK	0.303	0.303	0.06061	0.06061	0.04545	0.2121	0.01515
BCC	0.1748	0.5534	0.07767	0.02913	0.009709	0.1068	0.04854
D	0.1304	0.2174	0.4348	0.08696	0	0.08696	0.04348
M	0.1839	0.02691	0.04484	0.5471	0.07623	0.1121	0.008969
N	0.1156	0.03057	0.02386	0.1641	0.5787	0.05966	0.02759
PBK	0.1273	0.1227	0.04091	0.2364	0.1	0.3591	0.01364
VL	0.06897	0.06897	0.1724	0.1034	0.1724	0.06897	0.3448

Ground Truth

Classified as

0 0.1 0.2 0.3 0.4 0.5

Reference:

- [1] mathworks.com
- [2] bigdata-ir.com
- [3] howsam.org/convolutional-neural-network
- [4] fanology.ir/convolutional-neural-network
- [5] isic-archive.com